

SISTEMAS DE RECOMENDAÇÃO E SAÚDE MENTAL NO CAPITALISMO DE VIGILÂNCIA: A CURADORIA INTENCIONAL COMO INSTRUMENTO DE MITIGAÇÃO DA SOBRECARGA COGNITIVA

Recommendation Systems and Mental Health in Surveillance Capitalism: Intentional Curation as an Instrument to Mitigate Cognitive Overload

Fellype Samuel¹, Felipe Farias²

¹Graduando em Análise e Desenvolvimento de Sistemas, FAETERJ-Rio, Rio de Janeiro, Brasil.
E-mail: fellype.24104708360042@faeterj-rio.edu.br

²Graduando em Análise e Desenvolvimento de Sistemas, FAETERJ-Rio, Rio de Janeiro, Brasil.
E-mail: felipe.23204708360023@faeterj-rio.edu.br

³Doutor em História das Ciências e Pós-Doutorando em Ensino de Ciências e Saúde (FIOCRUZ), FAETERJ-Rio, Rio de Janeiro, Brasil.
E-mail: ricardo.marciano@faeterj-rio.edu.br

Resumo

Introdução: A economia da atenção e o capitalismo de vigilância impulsionam sistemas de recomendação focados na maximização do engajamento de curto prazo, associados à fadiga atencional e a impactos negativos na saúde mental. **Objetivo:** Propor e validar uma arquitetura algorítmica alternativa que priorize a atenção sustentável e a preservação da utilidade cognitiva. **Metodologia:** A arquitetura substitui a recompensa por engajamento bruto por um Score de Qualidade Multiobjetivo, modela a interação via Processos de Hawkes decompostos (Sistema 1 vs. Sistema 2) e introduz uma EDO de reserva cognitiva avaliada localmente por Edge AI. A validação foi realizada por Simulação Baseada em Agentes (ABM) com $N = 1.000$ agentes. **Resultados:** A arquitetura proposta preserva a reserva cognitiva (Cohen's $d = 3,25$; $p < 10^{-300}$) e reduz a divergência entrópica do usuário, demonstrando robustez em análises de sensibilidade. **Conclusão:** Os resultados oferecem um caminho técnico pragmático para sistemas de recomendação eticamente alinhados, provando que é possível otimizar a utilidade sustentável sem prescindir da eficiência técnica.

Palavras-chave: Sistemas de Recomendação; Saúde Mental; Capitalismo de Vigilância; Processos de Hawkes; Inteligência Humana.

Abstract

Introduction: The attention economy and surveillance capitalism drive recommendation systems focused on maximizing short-term engagement, associated with attentional fatigue and negative mental health impacts. **Objective:** To propose and validate an alternative algorithmic architecture that prioritizes sustainable attention and the preservation of cognitive utility. **Methodology:** The architecture replaces the brute engagement reward with a Multi-objective Quality Score, models interaction via decomposed Hawkes Processes (System 1 vs. System 2), and introduces an ODE for cognitive reserve evaluated locally through Edge AI. Validation was carried out using Agent-Based Modeling (ABM) with $N = 1,000$ agents. **Results:** The proposed architecture preserves cognitive reserve (Cohen's $d = 3.25$; $p < 10^{-300}$) and reduces user entropic divergence, demonstrating robustness in sensitivity analyses. **Conclusion:** The results offer a pragmatic technical path for ethically aligned recommender systems, proving that it is possible to optimize sustainable utility without sacrificing technical efficiency.

Keywords: Recommender Systems; Mental Health; Surveillance Capitalism; Hawkes Processes; Human Intelligence.

1 Introdução

Nas últimas duas décadas, as redes sociais tornaram-se o centro da vida social, da informação e do entretenimento humano. Contudo, avolumam-se as discussões empíricas sobre como tais ferramentas afetam a saúde mental, a capacidade de concentração e a qualidade do consumo *online*. A crise de atenção contemporânea não se resume a uma falha de disciplina individual, mas deriva de estruturas econômicas e tecnológicas que induzem um déficit cognitivo sistêmico (Hari, 2022). As plataformas são projetadas para maximizar a retenção por meio de ciclos de recompensa intermitente, instigando a verificação compulsiva.

Esse cenário opera sob a égide do “capitalismo de vigilância” (Zuboff, 2019), modelo em que cada interação é quantificada para alimentar algoritmos que mapeiam vulnerabilidades. Citton (2017) descreve uma “ecologia da atenção” na qual algoritmos bombardeiam o indivíduo com estímulos rápidos. A disputa converte a atenção em um ativo econômico. Os efeitos recaem de forma acentuada sobre jovens, com associações entre o uso intensivo de algoritmos e sintomas emocionais adversos (Costello et al., 2023). Relatórios institucionais corroboram que sistemas não supervisionados estão atrelados à exaustão e ansiedade digitais (Stanford HAI, 2021).

A literatura sociotécnica descreve as plataformas digitais como infraestruturas centrais de um regime de capitalismo de vigilância, no qual dados comportamentais são extraídos para a modulação de condutas e predição comercial (Zuboff, 2019). Especialistas apontam que a otimização calcada puramente no engajamento subverte os interesses do indivíduo (Harris, 2019). Citton (2017) documenta uma ecologia em que a escassez de foco é produzida de modo algorítmico e artificial por interações massivas de reatividade, enquanto métricas corroboram como essa exaustão consome componentes significativos do processamento deliberativo dos agentes no médio prazo (Allcott et al., 2021).

De forma a mitigar tais externalidades, consolida-se o campo de *Value-Aligned RecSys*, em que pesquisadores modelam algoritmos não baseados em simples predições brutas, contendo arranjos paralelos para o engajamento contínuo, a justiça ou a pluralidade em distribuição de ganhos na rede de contato do usuário (Stray et al., 2021). Por meio do *reinforcement learning* aplicado ao ambiente sociopolítico da plataforma, avalia-se que recompensas orientadas estritamente a fluxos ininterruptos fragmentam as teias colaborativas dos usuários (Carvalho, 2023).

Correlato a isso, o bem-estar digital costuma ser abordado pela adoção de dispositivos externos de autogestão, como *dashboards* e aplicativos de bloqueio (Forest Team, 2020; RescueTime, 2020), cuja efetividade é limitada por dependerem exclusivamente do autocontrole (Lyngs et al., 2019). Soluções efetivas advêm de mecanismos coercitivos projetados via fricções intencionais (Kushlev et al., 2022).

Os elos da economia comportamental com o *design* de sistemas fornecem métricas robustas. A segregação dual entre Sistema 1 (automático, impulsivo) e Sistema 2 (reflexivo, deliberativo) (Kahneman, 2011) e os limiares de sobrecarga cognitiva (Paas et al., 2023) têm direcionado novos desenvolvimentos. Interseccionando essa restrição fisiológica com Processos de Hawkes, é possível discernir se a reiteração da utilização baseia-se em excitação residual curta ou em utilidade orgânica prolongada (Rizoiu et al., 2017; Agarwal et al., 2024).

A convergência dessas discussões evidencia uma lacuna crítica: enquanto a literatura mapeia os riscos do capitalismo de vigilância e propõe modelos de alinhamento de valores, a implementação prática de ferramentas que integrem a regulação cognitiva em tempo real ainda é incipiente. O projeto *Be-Productive* preenche essa lacuna ao transpor a teoria da ecologia da atenção (Citton, 2017) e os modelos de Processos de Hawkes (Rizoiu et al., 2017) para uma arquitetura funcional de *Edge AI*, automatizando a preservação da reserva cognitiva através de travamentos algorítmicos baseados na dinâmica de sistemas.

Diante desta conjuntura, formula-se a seguinte questão de pesquisa: *É viável estruturar o núcleo de sistemas de recomendação para otimizar a utilidade sustentável e a intenção declarada do usuário, mitigando a dependência algorítmica?*

Este artigo propõe uma arquitetura algorítmica voltada à atenção sustentável. A Seção 2 descreve a metodologia e a arquitetura proposta; a Seção 3 apresenta os resultados e a discussão; e a Seção 4 consolida as conclusões.

2 Metodologia

2.1 A Matemática do Engajamento Imediato

Nos sistemas comerciais, a plataforma atua primariamente na maximização da interação de curto prazo. Seja $\mathcal{U}$ o conjunto de usuários e $\mathcal{I}$ o de itens, a política π otimiza:

$$\max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^T \gamma^t R_E(u, i, t) \right] \quad (1)$$

Onde $\gamma \in (0, 1]$ é o fator de desconto temporal e R_E representa a recompensa imediata (ex.: *clicks*). Esse ranqueamento está demonstrado no Algoritmo 1.

Algoritmo 1: Lógica Tradicional de Ranqueamento de Feed

Entrada: $post \in \mathcal{I}$, $usuario \in \mathcal{U}$

Saída: Pontuação baseada em interação iminente

- 1 $pontuacao \leftarrow (post.curtidas \times w_{curtida}) + (post.compartilhamentos \times w_{compartilhamento})$;
 - 2 **if** $pontuacao > LIMIA_{VIRALIDADE}$ **then**
 - 3 $_injetar_no_feed_global(post)$;
 - 4 **retornar** $pontuacao$;
-

2.2 Dicotomia Cognitiva e Processos de Hawkes

Para superar as mazelas inerentes e estruturais observadas nos sistemas de recomendação convencionais, propomos uma modelagem matemática da interação usuário-plataforma baseada em **Processos de Hawkes**, que permite **discernir quantitativamente dois regimes comportamentais** fundamentais: o consumo impulsivo (reativo) e o consumo intencional (deliberativo). Esta distinção operacionaliza, no domínio algorítmico, a teoria dos sistemas duais de Kahneman (2011), separando o **Sistema 1** (automático, rápido, emocional) do **Sistema 2** (reflexivo, lento, racional).

2.2.1 Fundamentos dos Processos de Hawkes

Um Processo de Hawkes é um processo pontual autorregressivo no qual a ocorrência de eventos passados aumenta a probabilidade de eventos futuros, modelando assim **excitação temporal** e **dependência histórica**. Formalmente, a intensidade condicional $\lambda(t)$ (taxa instantânea de ocorrência de eventos no instante t) é definida como:

$$\lambda(t) = \mu + \sum_{t_i < t} \phi(t - t_i)$$

onde $\mu > 0$ é a taxa base (eventos que ocorreriam mesmo sem influência externa) e $\phi(\cdot)$ é o **kernel de excitação**, que descreve como cada evento passado contribui para a intensidade atual. Tipicamente, adota-se um kernel exponencial decrescente $\phi(\Delta) = \alpha e^{-\beta \Delta}$, com α representando a magnitude da excitação e β a taxa de decaimento temporal.

No contexto de sistemas de recomendação, cada interação do usuário (clique, visualização, curtida) é um evento que **reforça a probabilidade de novas interações**, seja por gatilhos emocionais imediatos (Sistema 1) ou por interesse genuíno de longo prazo (Sistema 2). A modelagem via Hawkes permite capturar essa dinâmica de retroalimentação e, crucialmente, **decompor as fontes de excitação**.

2.2.2 Decomposição em Sistemas 1 e 2

A equação central desta subseção é:

$$\lambda(t) = \mu + \sum_{t_k \in \mathcal{K}, t_k < t} \alpha_1 e^{-\beta_1(t-t_k)} + \sum_{t_m \in \mathcal{M}, t_m < t} \alpha_2 e^{-\beta_2(t-t_m)} \quad (2)$$

onde:

- $\mathcal{K}$ é o conjunto de instantes de eventos classificados como **Sistema 1**: interações rápidas, superficiais e emocionalmente reativas - tipicamente curtidas, compartilhamentos impulsivos, cliques em *thumbnails* sensacionalistas, rolagem automática. Esses eventos são caracterizados por alta excitação imediata e rápido decaimento.
- $\mathcal{M}$ é o conjunto de instantes de eventos classificados como **Sistema 2**: interações que refletem intenção consciente e engajamento profundo - por exemplo, leitura completa de um artigo, visualização prolongada de um vídeo educativo, interações com conteúdo de interesse declarado. Esses eventos possuem excitação moderada, mas persistência temporal.

Os parâmetros $\alpha_1, \beta_1, \alpha_2, \beta_2$ são estimados para cada usuário (ou perfil) e refletem sua suscetibilidade a cada tipo de estímulo:

- $\alpha_1 \gg \alpha_2$: A excitação causada por eventos do Sistema 1 é muito maior do que a do Sistema 2. Isso significa que um clique impulsivo eleva fortemente a probabilidade de novos cliques no curto prazo - é o efeito “viral” ou “gatilho emocional”.
- $\beta_1 \gg \beta_2$: O decaimento da excitação do Sistema 1 é rápido; após poucos minutos, o efeito do evento impulsivo desaparece. Em contraste, $\beta_2 \rightarrow 0$ indica que a influência de um evento intencional **persiste por horas ou dias** - o usuário mantém um interesse latente por aquele tópico.

A **taxa base** μ captura a propensão inata do usuário a interagir independentemente de estímulos passados (por exemplo, checagem rotineira do aplicativo).

2.2.3 Interpretação Cognitiva e Implicações para o Design

A dicotomia modelada reflete diretamente a arquitetura cognitiva humana:

- **Sistema 1** corresponde aos atalhos heurísticos, respostas automáticas a estímulos salientes (cores vibrantes, rostos, novidades). No ambiente digital, é explorado por *design* que maximiza o *engagement* imediato via recompensas variáveis (Zuboff, 2019; Harris, 2019).
- **Sistema 2** envolve controle executivo, atenção sustentada e processamento deliberativo. É o recurso escasso que se esgota com a sobrecarga cognitiva (Paas et al., 2023).

Ao separar os kernels, podemos **quantificar o “peso” relativo de cada sistema na dinâmica de retorno do usuário**. Um usuário saudável deveria apresentar α_2 significativo e β_2 pequeno - ou seja, suas decisões de retorno seriam guiadas por interesses duradouros, não por picos de excitação fugazes. Por outro lado, usuários “viciados” ou excessivamente engajados exibem α_1 dominante e β_1 elevado, indicando que sua atividade é mantida por uma sucessão de gatilhos rápidos, sem formação de preferências estáveis.

2.2.4 Conexão com a Tabela Comparativa

A Tabela 1 explicita como essa modelagem se traduz em diferentes objetivos de otimização:

- **Modelo Baseline** (equação 1) maximiza a recompensa imediata R_E , o que equivale a **otimizar a excitação primária** α_1 . O sistema aprende a privilegiar conteúdos que geram picos de $\lambda(t)$ no curtíssimo prazo, exigindo alto volume de interações para sustentar a intensidade. Isso leva à **saturação atencional progressiva** - o usuário é bombardeado com estímulos cada vez mais fortes para manter a mesma resposta.
- **Modelo Proposto** incorpora na função objetivo (equação 3) uma penalidade explícita ao esgotamento cognitivo $\mathcal{L}(t)$ e prioriza eventos associados ao Sistema 2. Na prática, o ranqueamento favorece itens cujo histórico de interações do usuário indica baixo decaimento β_2 , ou seja, conteúdo com **utilidade persistente**. O sistema “aprende a esperar”: mesmo que um conteúdo não gere um clique imediato, se ele se alinha aos interesses profundos do usuário (α_2), será recomendado, pois seu efeito benéfico perdura.

A proteção cognitiva é garantida porque a própria dinâmica de Hawkes, quando analisada em tempo real, pode disparar intervenções (via Algoritmo 3) sempre que a razão $\frac{\alpha_1 e^{-\beta_1 \Delta}}{\alpha_2 e^{-\beta_2 \Delta}}$ ultrapassar um limiar – indicando que o usuário está sendo capturado por uma cascata de eventos impulsivos.

2.2.5 Aspectos Computacionais e Implementação em Edge AI

A estimação dos parâmetros $(\alpha_1, \beta_1, \alpha_2, \beta_2)$ e a classificação dos eventos em $\mathcal{K}$ ou $\mathcal{M}$ são realizadas **localmente no dispositivo do usuário** (Edge AI), garantindo privacidade *by design*. Cada evento de interação é anotado com metadados comportamentais (tempo de permanência, taxa de rolagem, alternância de contexto) que permitem inferir se a ação foi impulsiva ou intencional. Um classificador leve (por exemplo, uma regressão logística treinada offline) atribui o evento a um dos conjuntos.

A atualização dos parâmetros pode ser feita incrementalmente via *expectation-maximization on-line* ou filtros de partículas, mantendo o modelo adaptativo sem necessidade de enviar dados brutos ao servidor. A intensidade $\lambda(t)$ é recalculada a cada novo evento e utilizada tanto para ranqueamento quanto para monitoramento da fadiga.

2.2.6 Extensões e Generalizações

Embora tenhamos optado por kernels exponenciais por sua tratabilidade analítica e interpretabilidade, o framework pode ser estendido para kernels mais complexos (potência, exponencial potência) ou para modelos multidimensionais que capturem interações entre diferentes tipos de conteúdo. A separação em apenas dois sistemas é uma simplificação poderosa; poderiam ser considerados mais níveis (por exemplo, Sistema 0: reflexos fisiológicos), mas a dualidade mostrou-se suficiente para capturar a essência do problema de alinhamento cognitivo.

2.2.7 Síntese

A modelagem via Processos de Hawkes com kernels duals fornece uma **métrica contínua e temporalmente consciente** do engajamento, distinguindo o que é reativado que é reflexivo. Ela fundamenta matematicamente a transição de uma otimização cega por volume (*baseline*) para uma otimização orientada à **sustentabilidade atencional** (proposto). A Tabela 1 resume essa transformação: enquanto o baseline maximiza α_1 e exige volume, o modelo proposto prioriza α_2 e baixo β_2 , com impacto direto na preservação da reserva cognitiva via *Edge AI*. Essa distinção é a espinha dorsal de toda a arquitetura *Be-Productive*.

Tabela 1: Comparação Analítica das Arquiteturas

Parâmetro Matemático	Modelo Baseline	Modelo Proposto
Função Objetivo	$\max_{\pi} \sum \gamma^t R_E(u, i)$	$\max_{\mathcal{Q}} \sum \gamma^t U(u, i) - \mathcal{L}(t)$
Alvos Temporais	Otimiza excitação primária (α_1). Exige volume.	Prioriza interesse moderado (α_2). Baixo decaimento β_2 .
Impacto Cognitivo	Saturação atencional progressiva.	Proteção por <i>Edge AI</i> .

2.3 Score de Qualidade e Filtragem Multiobjetivo

A política de ranqueamento proposta substitui a métrica tradicional de engajamento imediato por um **Score de Qualidade** $\mathcal{Q}(i, u)$ que integra múltiplos objetivos, equilibrando relevância personalizada, feedback explícito do usuário e segurança de conteúdo. O objetivo é promover itens que não apenas interessem ao usuário, mas que também respeitem sua saúde cognitiva e estejam alinhados com padrões éticos pré-definidos.

2.3.1 Formulação Matemática do Score

A equação central é dada por:

$$\mathcal{Q}(i, u) = \underbrace{\left[\sum_{k=1}^K w_k \cdot f_k(i, u) + \sum_{j=1}^J \theta_j \cdot E_j(i, u) \right]}_{\text{Componente de mérito}} \times \underbrace{\min_m (1 - P_m(i))}_{\text{Fator de penalidade}}. \quad (3)$$

Vamos detalhar cada componente:

- $f_k(i, u)$ – **Características de pertinência**: São K funções que avaliam a adequação do item i ao perfil e contexto atual do usuário u . Exemplos incluem similaridade semântica com interesses de longo prazo, relevância temporal e qualidade intrínseca do item (autoridade da fonte, clareza). Os pesos w_k permitem priorizar diferentes facetas da pertinência.

- $E_j(i, u)$ – **Sinais de feedback explícito**: Representam J indicadores fornecidos diretamente pelo usuário ou deduzidos de suas ações conscientes, como avaliações explícitas, denúncias ou metas declaradas (ex.: modo “foco”). Os coeficientes θ_j ponderam a importância de cada sinal.

A soma ponderada desses dois grupos constitui a **base de mérito** do item, capturando a utilidade pessoal e a intencionalidade.

2.3.2 Filtragem Multiobjetivo via Penalidade Mínima

O fator multiplicativo $\min_m(1 - P_m(i))$ é o coração da filtragem multiobjetivo. Aqui, $P_m(i) \in [0, 1]$ é a probabilidade estimada por um classificador de IA (m -ésimo modelo) de que o item i seja **nocivo** segundo critérios como discurso de ódio (P_1), desinformação (P_2), conteúdo violento (P_3), clickbait (P_4) ou estímulos compulsivos (P_5).

O termo $1 - P_m(i)$ representa a **probabilidade de o item ser seguro**. Aplicar o operador **mínimo** implementa uma interpretação conservadora: a segurança do item é tão forte quanto seu **elo mais fraco**. Se **qualquer** classificador indicar alta probabilidade de nocividade ($P_m \approx 1$), o score final é efetivamente zerado, independentemente do mérito calculado. Essa abordagem evita que itens altamente relevantes, mas perigosos em uma dimensão específica, sejam mascarados por médias aritméticas, refletindo a filosofia de que certos riscos não são compensáveis.

2.3.3 Interpretação no Contexto do Sistema 2

O Score de Qualidade é a ferramenta que o **Sistema 2 otimizado** utiliza para promover conteúdos que atendam a objetivos de longo prazo. O fator de penalidade age como um **freio** contra conteúdos danosos, alinhando o algoritmo com a proteção da reserva cognitiva e da intencionalidade do usuário.

2.3.4 Considerações de Implementação e Edge AI

Os modelos *IA_Safety* são projetados para serem leves e executados preferencialmente na borda (*Edge AI*). A estrutura linear multiplicativa do score garante interpretabilidade, permitindo auditoria sobre qual classificador disparou uma penalidade. Além disso, a arquitetura é extensível, permitindo a adição de novos classificadores sem alterar a lógica central de agregação por norma mínima (*min-norm*).

Algoritmo 2: Cálculo do Score de Qualidade (Otimização do Sistema 2)

Entrada: $post \in \mathcal{I}$, $usuario \in \mathcal{U}$
Saída: Nota heurística $Q(i, u) \in \mathbb{R}$

- 1 $base_score \leftarrow \langle vetor_pertinencia, pesos_w \rangle + \langle vetor_feedback, pesos_\theta \rangle$;
- 2 $fator_penalidade \leftarrow 1.0$;
- 3 **para cada** $IA_Safety \in ModelosClassificadores$
 $p_nocivo \leftarrow IA_Safety.inferir_probabilidade(post)$;
- 4 $fator_penalidade \leftarrow \min(fator_penalidade, 1 - p_nocivo)$;
- 5 $score_final \leftarrow base_score \times fator_penalidade$;
- 6 **retornar** $score_final$;

2.4 EDO de Reserva e Edge AI

Esta subseção detalha o mecanismo de proteção ativa do usuário, que atua como um “airbag cognitivo” acionado antes do colapso atencional, integrando modelagem dinâmica e privacidade na borda.

2.4.1 O Conceito de Reserva Cognitiva ($R(t)$)

A variável $R(t)$ é uma abstração matemática da capacidade do usuário de manter o foco e tomar decisões deliberadas (**Sistema 2**). Ancorada nas teorias de *Ego Depletion* e Carga Cognitiva, a reserva é modelada como um recurso limitado: $R(t) \in [0, R_{\max}]$. Interações impulsivas drenam essa reserva, tornando o usuário vulnerável a gatilhos do **Sistema 1** e criando ciclos viciosos de consumo reativo.

2.4.2 Dinâmica do Esgotamento via EDO

A “lei do movimento” da reserva cognitiva é regida por uma Equação Diferencial Ordinária (EDO):

$$\frac{dR(t)}{dt} = S(R, t) - \mathcal{L}(X, t) \quad (4)$$

Onde a derivada $\frac{dR(t)}{dt}$ representa a taxa de variação instantânea. O termo $S(R, t)$ representa a **Taxa de Recuperação** (restauração homeostática), modelada como $\mu_{rest} \cdot (R_{\max} - R(t))$, indicando que a recuperação é mais eficiente quando a reserva está baixa. O termo $\mathcal{L}(X, t)$ quantifica o **Esgotamento** causado pelo ambiente digital:

$$\mathcal{L}(X, t) = \kappa_1 \cdot v_{scroll}(t) + \kappa_2 \cdot \nu_{alt}(t) \quad (5)$$

Aqui, v_{scroll} (velocidade de rolagem) e ν_{alt} (frequência de alternância de contexto) são sensores comportamentais. Velocidades elevadas indicam consumo superficial, enquanto alternâncias bruscas fragmentam a atenção. Os coeficientes κ_1 e κ_2 permitem a calibração personalizada do sistema conforme a sensibilidade do usuário.

2.4.3 Edge AI e Privacidade por Design

Visando evitar o recolhimento abusivo da vigilância *backend*, o controle da EDO ocorre privadamente no processo central executivo algorítmico do ambiente (**Edge AI**). Métricas puras de interação (v_{scroll}, ν_{alt}) são processadas localmente e nunca deixam o dispositivo. O *backend* recebe apenas sinais binários de intervenção, preservando o anonimato comportamental e garantindo que o sistema atue como um agente do usuário, não da plataforma.

2.4.4 O Algoritmo de Regulação de Fadiga

O Algoritmo 3 descreve a integração numérica da EDO em tempo real:

Algoritmo 3: Sub-rotina de Regulação de Fadiga (Execução On-Device)

Entrada: Fluxo de eventos DOM (v_{scroll}, ν_{alt}) no cliente local

```
1 enquanto sessao_ativa  $L_{atual} \leftarrow (\kappa_1 \times v_{scroll}) + (\kappa_2 \times \nu_{alt})$ ;  
2  $reserva\_R \leftarrow reserva\_R - (L_{atual} \times \Delta t)$ ;  
3 if  $reserva\_R \leq LIMIAR\_FADIGA\_CRITICA$  then  
4    $despachar\_evento(TIPO\_FRICCAO\_POSITIVA)$ ;  
5    $iniciar\_taxa\_recuperacao(\mu_{rest})$ ;
```

Quando a reserva cruza o limiar crítico, o sistema dispara uma **fricção positiva** (ex.: tons de cinza na interface, redução da fluidez de scroll ou mensagens de incentivo à pausa), induzindo um estado restaurativo onde o termo S se torna dominante, fechando o ciclo de feedback negativo e protegendo a saúde mental do usuário.

2.5 Desconto Hiperbólico e Modo Absoluto

Esta subseção aborda a inconsistência temporal das decisões humanas, introduzindo um mecanismo proativo de blindagem contra tentações de curto prazo, operando de forma binária e local.

2.5.1 A Armadilha do Desconto Hiperbólico

Seres humanos tendem a preferir gratificações instantâneas em detrimento de benefícios maiores no futuro, fenômeno onde o “eu presente” ignora os custos suportados pelo “eu futuro”. A equação do **Desconto Hiperbólico** formaliza essa queda acentuada de valor no curto prazo:

$$V_p = \frac{V}{1 + k \cdot D} \quad (6)$$

Onde:

- V (Valor Real): O valor intrínseco da recompensa futura (ex.: conclusão de um projeto, saúde mental).
- V_p (Valor Percebido): O valor subjetivo no instante da decisão.
- D (Atraso): O tempo de espera. Sistemas viciantes operam com $D \approx 0$ para manter V_p artificialmente alto.
- k (Constante de Desconto): Representa a impulsividade individual, podendo ser inferida localmente via Edge AI.

2.5.2 Modo Absoluto: O Pacto de Ulisses Digital

Em contraponto à exploração desse viés, o **Modo Absoluto** atua como um dispositivo de comprometimento prévio voluntário. Diferente de ferramentas convencionais, este modo remove as opções de desistência e altera a recomendação.

2.5.3 Algoritmo de Blindagem Cognitiva

O Algoritmo 4 descreve a imposição estrutural do foco:

Algoritmo 4: Protocolo de Blindagem Cognitiva (Modo Absoluto)

Entrada: Objeto *sessao* contendo restrições temporais e meta

```
1 if sessao.modos_absolutos_ativos == VERDADEIRO then
2   desabilitar_botoes_de_cancelamento();
3   para cada conteudo ∈ buffer_de_recomendacao if
4     conteudo.categoria ≠ sessao.meta_declarada then
5       conteudo.V_percebido ← 0;
6       conteudo.renderizar ← FALSO;
7   iniciar_timer_blindado(sessao.duracao);
```

Toda a lógica é executada localmente (**Edge AI**), garantindo que a *meta_declarada* nunca seja exposta ao servidor. O sistema torna-se “cego” a distrações, forçando o cumprimento do compromisso assumido pelo usuário em seu momento de lucidez racional (**Sistema 2**).

2.6 Validação por Simulação Baseada em Agentes

A validação empírica foi conduzida via Simulação Baseada em Agentes (ABM) com $N = 1.000$ agentes e horizonte temporal $T = 60$ passos, totalizando 60 000 observações por condição. Os parâmetros de entrada são:

- **N agentes:** População gerada com distribuições log-normais: $\mu \sim \text{Lognormal}(0.5, 0.2)$ (taxa base de interação), $k \sim \text{Lognormal}(-1.0, 0.5)$ (constante de desconto), $R_{\max} \sim \mathcal{N}(100, 15)$.
- **T timesteps:** 60 interações.
- **Seed fixa:** `np.random.seed(42)` para replicabilidade.

3 Resultados e Discussão

A validação da tese repousa sobre dois pilares estatísticos fundamentais:

- **Significância Estatística ($p < 10^{-300}$):** A probabilidade de observarmos a diferença entre os modelos sustentável e *baseline* por mero acaso é virtualmente nula. O teste de Mann-Whitney U corrigido confirma que a melhoria é consequência direta da arquitetura proposta.
- **Tamanho de Efeito (Cohen's $d = 3.25$):** Enquanto o p-valor indica a existência do efeito, o valor de 3.25 quantifica sua magnitude profunda. Em contextos comportamentais, um valor de 0.8 já indica um efeito largo; nosso resultado aponta que a média do grupo sustentável está a mais de três desvios padrão acima da *baseline*, indicando uma transformação radical na experiência atencional.

Traduzimos o conceito abstrato de reserva cognitiva em uma métrica concreta: a Área Sob a Curva (AUC). Implementada via Regra do Trapézio em `metrics.py`, a AUC sumariza toda a trajetória do agente em um índice de “energia cognitiva” preservada.

Um sistema *Value-Aligned* deve assegurar que o tempo gasto seja de qualidade. Utilizamos a Divergência de Kullback-Leibler (D_{KL}) para medir a “distância” entre a intenção declarada pelo agente (P) — PRODUTIVIDADE ou ENTRETENIMENTO — e a alocação real de tempo imposta pelo sistema (Q).

Para afastar a hipótese de uma “solução de laboratório” excessivamente parametrizada, conduzimos testes de estresse via Análise de Sensibilidade Monte Carlo (`sensitivity.py`). Realizamos uma varredura massiva no espaço de possibilidades, alterando parâmetros de fricção (κ_1) e redução de velocidade.

A síntese dos resultados aponta que o objetivo central da pesquisa foi atingido: é factível projetar sistemas de recomendação que otimizem a utilidade cognitiva sem prescindir da eficiência técnica. A integração de *Edge AI* com filtros *min-norm* permite que a arquitetura aja como um “airbag”, protegendo o usuário antes do colapso atencional.

Sob a ótica ética, a solução distancia-se de formas de “vigilância benevolente” ao adotar um modelo estritamente *opt-in*. Trata-se de um contrato de autovinculação (*Ulysses Pact*), alinhado a movimentos contemporâneos de bem-estar digital ([Center for Humane Technology, 2026](#)), onde a privacidade *by design* é garantida pela execução on-device. Reconhecemos limitações inerentes à simulação, como a ausência de variáveis sociais exógenas (ex.: notificações de terceiros), o que fundamenta a necessidade de futuras validações *in-vivo* e estudos focados em populações vulneráveis ([Lyngs et al., 2019](#); [Costello et al., 2023](#); [Brasil, 2021](#)).




Figura 1: Estimativa de Densidade de Kernel (KDE) da Área Sob a Curva (AUC) da reserva cognitiva $R(t)$. A curva vermelha (*baseline*) mostra a massa probabilística concentrada em valores baixos, indicando esgotamento rápido. O deslocamento da curva azul (*Be-Productive*) para a direita ($\mu_{sust} > \mu_{base}$) visualiza o Cohen's d de 3.25, provando a preservação superior da capacidade deliberativa ($N = 1000$).




Figura 2: Análise de Divergência KL ($D_{KL}(P||Q)$). O *boxplot baseline* revela alta mediana e dispersão, indicando que o sistema tradicional rotineiramente sequestra a agência do usuário. No modelo proposto, a dispersão é drasticamente reduzida e a mediana aproxima-se de zero, confirmando que em 90% dos casos ($p \in [0.9, 0.1]$) a alocação de conteúdo respeita os objetivos do Sistema 2.




Figura 3: Manifold de Robustez Atencional. A superfície de resposta mapeia o ΔAUC (Sustentável - Baseline). A hegemonia da coloração verde em todo o espaço de estados viável demonstra a persistência do benefício algorítmico ($p < 10^{-300}$), independentemente de flutuações nas condições externas ou no perfil dos agentes. O sistema é, portanto, robusto e resiliente.

4 Conclusão

Este trabalho consolidou e quantificou a viabilidade de uma arquitetura algorítmica voltada à atenção sustentável. Resumimos as quatro frentes de contribuição: (1) Processos de Hawkes para diferenciação qualitativa de consumo; (2) EDO de Reserva para restrição cinemática; (3) Edge AI como padrão de privacidade ouro; e (4) Blindagem cognitiva contra o desconto hiperbólico.

Com evidências robustas ($N = 1000, d = 3.25, p < 10^{-300}$), comprovamos que sistemas tecnológicos podem e devem abdicar da predação atencional em favor da agência humana. O *Be-Productive* estabelece um novo paradigma para a Interação Humano-Computador, provando que o alinhamento de valores não é apenas um imperativo filosófico, mas uma factibilidade de engenharia.

Referências

- Agarwal, A., Usunier, N., Lazaric, A., and Nickel, M. (2024). Disentangling system-1 and system-2 contributions to user return with hawkes processes. *arXiv preprint arXiv:2406.01611*.
- Allcott, H. et al. (2021). Digital addiction. NBER Working Paper 28936, National Bureau of Economic Research.
- Brasil (2021). Saúde mental.
- Carvalho, F. (2023). Modelling the recommender alignment problem. Master's thesis, Master's Thesis.
- Center for Humane Technology (2020–2026). Time well spent movement.
- Citton, Y. (2017). *The Ecology of Attention*. Polity Press, Cambridge.

- Costello, N. et al. (2023). Algorithms, addiction, and adolescent mental health. *American Journal of Law & Medicine*.
- Forest Team (2020). Forest: Stay focused, be present.
- Hari, J. (2022). *Foco Roubado*. Vestígio, Rio de Janeiro.
- Harris, T. (2019). Optimizing for engagement. Testimony before U.S. Senate.
- Kahneman, D. (2011). *Thinking, Fast and Slow*. Farrar, Straus and Giroux, New York.
- Kushlev, K. et al. (2022). A nudge-based intervention to reduce problematic smartphone use. *Computers in Human Behavior*.
- Lyngs, U. et al. (2019). Self-control in cyberspace. In *CHI 2019*.
- Paas, F. et al. (2023). Cognitive load theory. *Journal of Medical Education*.
- RescueTime (2020). Rescuetime.
- Rizoiu, M.-A. et al. (2017). Expecting to be hip: Hawkes intensity processes for social media popularity. In *WWW 2017*.
- Stanford HAI (2021). A psychiatrist's perspective on social media algorithms and mental health.
- Stray, J. et al. (2021). What are you optimizing for? aligning recommender systems with human values. *ICML 2021*. *arXiv:2107.10939*.
- Zuboff, S. (2019). *The Age of Surveillance Capitalism*. PublicAffairs, New York.

Apêndice: Disponibilidade de Dados e Código

Todos os módulos em rotinas de ensaios e componentes algorítmicos em *scripts* contendo o rastilho operacional, incluindo registros computados para verificação estatística, encontram-se disponíveis integralmente sob versionamentos padronizados estritos para replicabilidade.