

SISTEMAS DE RECOMENDAÇÃO E SAÚDE MENTAL NO CAPITALISMO DE VIGILÂNCIA: A CURADORIA INTENCIONAL COMO INSTRUMENTO DE MITIGAÇÃO DA SOBRECARGA COGNITIVA

Fellype Samuel [FAETERJ-RIO de Quintino, RJ, Brasil]

Felipe Farias [FAETERJ-RIO de Quintino, RJ, Brasil]

Ricardo Marciano [FAETERJ-RIO de Quintino, RJ, Brasil]

✉ fellype.24104708360042@faeterj-rio.edu.br, felipe.23204708360023@faeterj-rio.edu.br, ricardo.marciano@faeterj-rio.edu.br

Received: DD Month YYYY • Accepted: DD Month YYYY • Published: DD Month YYYY

Abstract. A economia da atenção e o paradigma do capitalismo de vigilância têm impulsionado o *design* de sistemas de recomendação focados na maximização irrestrita do engajamento de curto prazo. Embora eficientes para métricas comerciais, tais sistemas arquitetônicos frequentemente negligenciam a utilidade cognitiva de longo prazo. O presente artigo técnico visa propor e validar uma arquitetura algorítmica alternativa que priorize a atenção sustentável. A metodologia empregada substitui a recompensa por engajamento bruto por um *Score* de Qualidade Multiobjetivo, reestruturando a interação via Processos de Hawkes decompostos, distinguindo computacionalmente os Sistemas 1 e 2. O balanço contínuo é modulado por uma Equação Diferencial Ordinária (EDO) local processada através de paradigmas de *Edge AI*. O modelo foi endossado e iterado em Simulação Baseada em Agentes (ABM) com $N = 1.000$ autômatos, provendo que as mudanças na topologia das recomendações blindam as reservas cognitivas dos interagentes ($d = 3.25$; $p < 10^{-300}$). Em síntese, a arquitetura elaborada comprova que o alinhamento axiomático ao usuário não prejudica a eficácia do motor probabilístico técnico, assentando bases sólidas para políticas de recomendação em benefício ético.

Keywords: Sistemas de Recomendação, Aprendizado de Máquina, Edge AI, Processos de Hawkes, Modelagem Baseada em Agentes

1 Introdução

Nas últimas duas décadas, as redes sociais tornaram-se o centro da vida social, da informação e do entretenimento humano. Contudo, avolumam-se as discussões empíricas sobre como tais ferramentas afetam a saúde mental, a capacidade de concentração e a qualidade do consumo *online*. A crise de atenção contemporânea não se resume a uma falha de disciplina individual, mas deriva de estruturas econômicas e tecnológicas que induzem um déficit cognitivo sistêmico [Hari, 2022]. As plataformas são projetadas para maximizar a retenção por meio de ciclos de recompensa intermitente, instigando a verificação compulsiva.

Esse cenário opera sob a égide do “capitalismo de vigilância” [Zuboff, 2019], modelo em que cada interação é quantificada para alimentar algoritmos que mapeiam vulnerabilidades. Citton [2017] descreve uma “ecologia da atenção” na qual algoritmos bombardeiam o indivíduo com estímulos rápidos. A disputa converte a atenção em um ativo econômico. Os efeitos recaem de forma acentuada sobre jovens, com associações entre o uso intensivo de algoritmos e sintomas emocionais adversos [Costello and Linn, 2023]. Relatórios institucionais corroboram que sistemas não supervisionados estão atrelados à exaustão e ansiedade digitais [Center for AI in Education, Stanford University, 2021].

A literatura sociotécnica descreve as plataformas digitais

como infraestruturas centrais de um regime de capitalismo de vigilância, no qual dados comportamentais são extraídos para a modulação de condutas e predição comercial [Zuboff, 2019]. Especialistas apontam que a otimização calcada puramente no engajamento subverte os interesses do indivíduo [Harris, 2019]. Citton [2017] documenta uma ecologia em que a escassez de foco é produzida de modo algorítmico e artificial por interações massivas de reatividade, enquanto métricas corroboram como essa exaustão consome componentes significativos do processamento deliberativo dos agentes no médio prazo [Allcott et al., 2021].

De forma a mitigar tais externalidades, consolida-se o campo de *Value-Aligned RecSys*, em que pesquisadores modelam algoritmos não baseados em simples predições brutas, contendo arranjos paralelos para o engajamento contínuo, a justiça ou a pluralidade em distribuição de ganhos na rede de contato do usuário [Stray et al., 2021]. Por meio do *reinforcement learning* aplicado ao ambiente sociopolítico da plataforma, avalia-se que recompensas orientadas estritamente a fluxos ininterruptos fragmentam as teias colaborativas dos usuários [Carvalho, 2023]. Correlato a isso, o bem-estar digital costuma ser abordado pela adoção de dispositivos externos de autogestão, como *dashboards* e aplicativos de bloqueio [??], cuja efetividade é limitada por dependerem exclusivamente do autocontrole [Lyngs et al., 2019]. Soluções efetivas advêm de mecanismos coercitivos projeta-

dos via fricções intencionais [Kushlev et al., 2022].

Neste cenário, propomos uma reformulação do núcleo funcional de algoritmos de recomendação em favor de utilidade sustentável. Apresentamos o modelo *Be-Productive*, que utiliza a instrumentação matemática dos Processos de Hawkes para dissociabilidade das facetas cognitivas [Kahneman, 2011; Paas and Sweller, 2023] integradas sob um ciclo analítico de restrição rodando em *Edge AI* na cliente doméstica.

2 Trabalhos Relacionados

A investigação sobre sistemas de recomendação que transcendem a métrica do engajamento imediato encontra solo em diversas frentes contemporâneas da Interação Humano-Computador (IHC) e da Ética em IA.

2.1 Economia da Atenção e Bem-Estar Digital

Estudos pioneiros de Zuboff [2019] e Harris [2019] denunciaram os perigos do design persuasivo, rotulando-o como uma forma de extração predatória. Lyngs et al. [2019] avaliaram diversas ferramentas de autocontrole assistido, como bloqueadores de sites e timers de uso, concluindo que sua eficácia é limitada quando a arquitetura do sistema de recomendação continua operando sob incentivos opostos. Nossa proposta diferencia-se ao integrar a mitigação da sobrecarga cognitiva diretamente no núcleo do algoritmo de classificação.

2.2 Processamento Dual e Carga Cognitiva

A aplicação da Teoria do Processo Dual de Kahneman [2011] em sistemas digitais tem sido explorada para identificar interações impulsivas. Agarwal et al. [2024] propuseram o uso de Modelos de Hawkes para monitorar o comportamento de usuários em redes sociais, focando na distinção entre o “clique por reflexo” e a “escolha deliberada”. No entanto, a maioria desses modelos permanece no plano analítico; o *Be-Productive* avança ao utilizar essa modelagem para retroalimentar o ranking de conteúdo em tempo real.

2.3 Value-Aligned Recommendations

A área de *Value-Alignment* busca alinhar os objetivos da IA com os valores humanos. Stray et al. [2021] discutem a necessidade de métricas de bem-estar que substituam o tempo de tela. Nosso trabalho operacionaliza essas métricas através do Score de Qualidade Multiobjetivo e da EDO de Reserva Cognitiva, oferecendo uma implementação técnica concreta para o que antes eram diretrizes filosóficas.

3 Metodologia e Arquitetura Proposta

3.1 Dicotomia Cognitiva e Processos de Hawkes

Para superar as mazelas inerentes e estruturais observadas nos sistemas de recomendação convencionais, propo-

mos uma modelagem matemática da interação usuário-plataforma baseada em Processos de Hawkes, que permite discernir quantitativamente dois regimes comportamentais fundamentais: o consumo impulsivo (reativo) e o consumo intencional (deliberativo). Esta distinção operacionaliza, no domínio algorítmico, a teoria dos sistemas duais de Kahneman [2011], separando o Sistema 1 (automático, rápido, emocional) do Sistema 2 (reflexivo, lento, racional).

3.1.1 Fundamentos dos Processos de Hawkes

Um Processo de Hawkes é um processo pontual autorregressivo no qual a ocorrência de eventos passados aumenta a probabilidade de eventos futuros, modelando assim excitação temporal e dependência histórica. Formalmente, a intensidade condicional $\lambda(t)$ (taxa instantânea de ocorrência de eventos no instante t) é definida como:

$$\lambda(t) = \mu + \sum_{t_i < t} \phi(t - t_i) \quad (1)$$

onde $\mu > 0$ é a taxa base (eventos que ocorreriam mesmo sem influência externa) e $\phi(\cdot)$ é o kernel de excitação, que descreve como cada evento passado contribui para a intensidade atual. Tipicamente, adota-se um kernel exponencial decrescente $\phi(\Delta) = \alpha e^{-\beta \Delta}$, com α representando a magnitude da excitação e β a taxa de decaimento temporal.

No contexto de sistemas de recomendação, cada interação do usuário (clique, visualização, curta) é um evento que reforça a probabilidade de novas interações, seja por gatilhos emocionais imediatos (Sistema 1) ou por interesse genuíno de longo prazo (Sistema 2). A modelagem via Hawkes permite capturar essa dinâmica de retroalimentação e, crucialmente, decompor as fontes de excitação.

3.1.2 Decomposição em Sistemas 1 e 2

Refutamos a união cega dos pulsos de usuário. Modela-se a intensidade $\lambda(t)$ decompondo as fontes de excitação em dois regimes que operacionalizam a teoria de Kahneman [2011]:

$$\lambda(t) = \mu + \underbrace{\sum_{t_k \in \mathcal{K}, t_k < t} \alpha_1 e^{-\beta_1(t-t_k)}}_{\text{Sistema 1 / Reativo}} + \underbrace{\sum_{t_m \in \mathcal{M}, t_m < t} \alpha_2 e^{-\beta_2(t-t_m)}}_{\text{Sistema 2 / Intencional}} \quad (2)$$

onde:

- $\mathcal{K}$ é o conjunto de instantes de eventos classificados como Sistema 1: interações rápidas, superficiais e emocionalmente reativas – tipicamente curtidas, compartilhamentos impulsivos, cliques em *thumbnails* sensacionalistas, rolagem automática. Esses eventos são caracterizados por alta excitação imediata e rápido decaimento.
- $\mathcal{M}$ é o conjunto de instantes de eventos classificados como Sistema 2: interações que refletem intenção consciente e engajamento profundo – por exemplo, leitura

completa de um artigo, visualização prolongada de um vídeo educativo, interações com conteúdo de interesse declarado. Esses eventos possuem excitação moderada, mas persistência temporal.

Os parâmetros $\alpha_1, \beta_1, \alpha_2, \beta_2$ são estimados para cada usuário e refletem sua suscetibilidade a cada tipo de estímulo. Observa-se tipicamente $\alpha_1 \gg \alpha_2$ (o efeito viral ou gatilho emocional eleva fortemente a probabilidade de novos cliques no curto prazo) e $\beta_1 \gg \beta_2$ (o decaimento do Sistema 1 é rápido, enquanto o Sistema 2 persiste por horas ou dias).

3.1.3 Interpretação Cognitiva e Implicações para o Design

A dicotomia modelada reflete diretamente a arquitetura cognitiva humana. O Sistema 1 corresponde aos atalhos heurísticos e respostas automáticas a estímulos salientes (cores vibrantes, rostos, novidades), explorados por *designs* que maximizam o *engagement* imediato [Zuboff, 2019; Harris, 2019]. Já o Sistema 2 envolve controle executivo e atenção sustentada, sendo o recurso escasso que se esgota com a sobrecarga cognitiva [Paas and Sweller, 2023].

Ao separar os kernels, podemos quantificar o “peso” relativo de cada sistema na dinâmica de retorno do usuário. Um usuário saudável deveria apresentar α_2 significativo e β_2 pequeno. Usuários sob estresse ou “viciados” exibem α_1 dominante e β_1 elevado, indicando atividade mantida por sucessão de gatilhos rápidos sem formação de preferências estáveis.

A Tabela 1 explicita como essa modelagem se traduz em diferentes objetivos de otimização. O Modelo Baseline maximiza a recompensa imediata R_E (Eq. 1), equivalendo a otimizar a excitação primária α_1 , o que leva à saturação atencional progressiva. O Modelo Proposto incorpora uma penalidade explícita ao esgotamento cognitivo $\mathcal{L}(t)$ e prioriza eventos associados ao Sistema 2.

3.1.4 Aspectos Computacionais e Implementação em Edge AI

A estimação dos parâmetros e a classificação dos eventos em $\mathcal{K}$ ou $\mathcal{M}$ são realizadas localmente no dispositivo do usuário (Edge AI), garantindo privacidade *by design*. Cada interação é anotada com metadados comportamentais (tempo de permanência, taxa de rolagem, alternância de contexto) que permitem inferir se a ação foi impulsiva ou intencional. Um classificador leve (ex: regressão logística treinada *offline*) atribui o evento a um dos conjuntos. A atualização é feita incrementalmente via *expectation-maximization on-line*, mantendo o modelo adaptativo sem enviar dados brutos ao servidor.

3.2 Score de Qualidade e Filtragem Multiobjetivo

A política de ranqueamento proposta substitui a métrica tradicional de engajamento imediato por um Score de Qualidade $\mathcal{Q}(i, u)$ que integra múltiplos objetivos, equilibrando relevância personalizada, *feedback* explícito do usuário e segurança de conteúdo. O objetivo é promover itens que não apenas interessem ao usuário, mas que também respeitem sua

saúde cognitiva e estejam alinhados com padrões éticos pré-definidos.

3.2.1 Formulação Matemática do Score

A equação central é dada por:

$$\mathcal{Q}(i, u) = \underbrace{\left[\sum_{k=1}^K w_k f_k(i, u) + \sum_{j=1}^J \theta_j E_j(i, u) \right]}_{\text{Componente de mérito}} \times \underbrace{\min_m(1 - P_m(i))}_{\text{Fator de penalidade}} \quad (3)$$

Vamos detalhar cada componente:

- $f_k(i, u)$ – Características de pertinência: São K funções que avaliam a adequação do item i ao perfil e contexto atual do usuário u . Exemplos incluem similaridade semântica com interesses de longo prazo, relevância temporal e qualidade intrínseca do item (autoridade da fonte, clareza). Os pesos w_k permitem priorizar diferentes facetas da pertinência.
- $E_j(i, u)$ – Sinais de *feedback* explícito: Representam J indicadores fornecidos diretamente pelo usuário ou deduzidos de suas ações conscientes, como avaliações explícitas, denúncias ou metas declaradas (ex: modo “foco”). Os coeficientes θ_j ponderam a importância de cada sinal.

A soma ponderada desses dois grupos constitui a base de mérito do item, capturando a utilidade pessoal e a intencionalidade.

3.2.2 Filtragem Multiobjetivo via Penalidade Mínima

O fator multiplicativo $\min_m(1 - P_m(i))$ é o coração da filtragem multiobjetivo. Aqui, $P_m(i) \in [0, 1]$ é a probabilidade estimada por um classificador de IA (m -ésimo modelo) de que o item i seja nocivo segundo critérios como discurso de ódio (P_1), desinformação (P_2), conteúdo violento (P_3), *clickbait* (P_4) ou estímulos compulsivos (P_5).

O termo $1 - P_m(i)$ representa a probabilidade de o item ser seguro. Aplicar o operador mínimo implementa uma interpretação conservadora: a segurança do item é tão forte quanto seu elo mais fraco. Se qualquer classificador indicar alta probabilidade de nocividade ($P_m \approx 1$), o *score* final é efetivamente zerado, independentemente do mérito calculado. Essa abordagem evita que itens altamente relevantes, mas perigosos em uma dimensão específica, sejam mascarados por médias aritméticas, refletindo a filosofia de que certos riscos não são compensáveis.

3.2.3 Interpretação no Contexto do Sistema 2

O Score de Qualidade é a ferramenta que o Sistema 2 otimizado utiliza para promover conteúdos que atendam a objetivos de longo prazo. O fator de penalidade age como

Table 1. Comparação Analítica das Arquiteturas

Parâmetro Matemático	Modelo Baseline	Modelo Proposto
Função Objetivo	$\max_{\pi} \sum \gamma^t R_E(u, i)$	$\max_Q \sum \gamma^t \mathcal{U}(u, i) - \mathcal{L}(t)$
Alvos Temporais	Otimiza excitação primária (α_1). Exige volume.	Prioriza interesse moderado (α_2). Baixo decaimento β_2 .
Impacto Cognitivo	Saturação atencional progressiva.	Proteção por <i>Edge AI</i> .

um freio contra conteúdos danosos, alinhando o algoritmo com a proteção da reserva cognitiva e da intencionalidade do usuário.

3.2.4 Considerações de Implementação e Edge AI

Os modelos *IA_Safety* são projetados para serem leves e executados preferencialmente na borda (*Edge AI*). A estrutura linear multiplicativa do *score* garante interpretabilidade, permitindo auditoria sobre qual classificador disparou uma penalidade. Além disso, a arquitetura é extensível, permitindo a adição de novos classificadores sem alterar a lógica central de agregação por norma mínima (*min-norm*). O Algoritmo 1 detalha essa lógica.

Algoritmo 1: Cálculo do Score de Qualidade (Otimização do Sistema 2)

Entrada: $post \in \mathcal{I}$, $usuario \in \mathcal{U}$
Saída: Nota heurística $Q(i, u) \in \mathbb{R}$

- 1 $base_score \leftarrow \langle vetor_pertinencia, pesos_w \rangle + \langle vetor_feedback, pesos_\theta \rangle$;
- 2 $fator_penalidade \leftarrow 1.0$;
- 3 **for** cada $IA_Safety \in ModelosClassificadores$ **do**
- 4 $p_nocivo \leftarrow IA_Safety.inferir_probabilidade(post)$;
- 5 $fator_penalidade \leftarrow \min(fator_penalidade, 1 - p_nocivo)$;
- 6 $score_final \leftarrow base_score \times fator_penalidade$;
- 7 **retornar** $score_final$;

3.3 EDO de Reserva e Edge AI

Esta subseção detalha o mecanismo de proteção ativa do usuário, que atua como um “airbag cognitivo” acionado antes do colapso atencional, integrando modelagem dinâmica e privacidade na borda.

3.3.1 O Conceito de Reserva Cognitiva ($R(t)$)

A variável $R(t)$ é uma abstração matemática da capacidade do usuário de manter o foco e tomar decisões deliberadas (Sistema 2). Ancorada nas teorias de *Ego Depletion* e Carga Cognitiva, a reserva é modelada como um recurso limitado: $R(t) \in [0, R_{max}]$. Interações impulsivas drenam essa reserva, tornando o usuário vulnerável a gatilhos do Sistema 1 e criando ciclos viciosos de consumo reativo.

3.3.2 Dinâmica do Esgotamento via EDO

A “lei do movimento” da reserva cognitiva é regida por uma Equação Diferencial Ordinária (EDO):

$$\frac{dR(t)}{dt} = S(R, t) - \mathcal{L}(X, t) \quad (4)$$

Onde a derivada $dR(t)/dt$ representa a taxa de variação instantânea. O termo $S(R, t)$ representa a Taxa de Recuperação (restauração homeostática), modelada como $\mu_{rest} \cdot (R_{max} - R(t))$, indicando que a recuperação é mais eficiente quando a reserva está baixa. O termo $\mathcal{L}(X, t)$ quantifica o Esgotamento causado pelo ambiente digital:

$$\mathcal{L}(X, t) = \kappa_1 v_{scroll}(t) + \kappa_2 \nu_{alt}(t) \quad (5)$$

Aqui, v_{scroll} (velocidade de rolagem) e ν_{alt} (frequência de alternância de contexto) são sensores comportamentais. Velocidades elevadas indicam consumo superficial, enquanto alternâncias bruscas fragmentam a atenção. Os coeficientes κ_1 e κ_2 permitem a calibração personalizada do sistema conforme a sensibilidade do usuário.

3.3.3 Edge AI e Privacidade por Design

Visando evitar o recolhimento abusivo da vigilância *backend*, o controle da EDO ocorre privadamente no processo central executivo algorítmico do ambiente (*Edge AI*). Métricas puras de interação são processadas localmente e nunca deixam o dispositivo. O *backend* recebe apenas sinais binários de intervenção, preservando o anonimato comportamental e garantindo que o sistema atue como um agente do usuário, não da plataforma.

3.3.4 O Algoritmo de Regulação de Fadiga

O Algoritmo 2 descreve a integração numérica da EDO em tempo real. Quando a reserva cruza o limiar crítico, o sistema dispara uma fricção positiva (ex: tons de cinza na interface, redução da fluidez de *scroll* ou mensagens de incentivo à pausa), induzindo um estado restaurativo onde o termo S se torna dominante.

3.4 Desconto Hiperbólico e Modo Absoluto

Esta subseção aborda a inconsistência temporal das decisões humanas, introduzindo um mecanismo proativo de blindagem contra tentações de curto prazo, operando de forma binária e local.

Algoritmo 2: Sub-rotina de Regulação de Fadiga (Execução On-Device)

Entrada: Fluxo de eventos DOM (v_{scroll}, ν_{alt})

```

1 enquanto sessao_ativa
   $\mathcal{L}_{atual} \leftarrow (\kappa_1 \times v_{scroll}) + (\kappa_2 \times \nu_{alt});$ 
2  $R \leftarrow R - (\mathcal{L}_{atual} \times \Delta t);$ 
3 if  $R \leq LIMIAR\_FADIGA$  then
4    $despachar\_evento(FRICCAO\_POSITIVA);$ 
5    $iniciar\_taxa\_recuperacao(\mu_{rest});$ 

```

3.4.1 A Armadilha do Desconto Hiperbólico

Seres humanos tendem a preferir gratificações instantâneas em detrimento de benefícios maiores no futuro, fenômeno onde o “eu presente” ignora os custos suportados pelo “eu futuro”. A equação do Desconto Hiperbólico formaliza essa queda acentuada de valor no curto prazo:

$$V_p = \frac{V}{1 + k \cdot D} \quad (6)$$

Onde V é o valor intrínseco da recompensa futura (ex: conclusão de um projeto), V_p é o valor percebido no instante da decisão, D é o atraso e k é a constante de impulsividade. Sistemas viciantes operam com $D \approx 0$ para manter V_p artificialmente alto.

3.4.2 Modo Absoluto: O Pacto de Ulisses Digital

Em contraponto à exploração desse viés, o Modo Absoluto atua como um dispositivo de comprometimento prévio voluntário. Diferente de ferramentas convencionais, este modo remove as opções de desistência e altera a recomendação. Toda a lógica é executada localmente (*Edge AI*), garantindo que a meta declarada nunca seja exposta ao servidor. O sistema torna-se “cego” a distrações, forçando o cumprimento do compromisso assumido pelo usuário em seu momento de lucidez racional (Sistema 2). O Algoritmo 3 descreve essa imposição estrutural do foco.

Algoritmo 3: Protocolo de Blindagem Cognitiva (Modo Absoluto)

Entrada: Objeto *sessao* contendo restrições temporais e meta

```

1 if sessao.modos_absoluto_ativo == VERDADEIRO then
2    $desabilitar\_botoes\_de\_cancelamento();$ 
3   for cada  $conteudo \in buffer\_de\_recomendacao$  do
4     if  $conteudo.categoria \neq sessao.meta\_declarada$  then
5        $conteudo.V\_percebido \leftarrow 0;$ 
6        $conteudo.renderizar \leftarrow FALSO;$ 
7    $iniciar\_timer\_blindado(sessao.duracao);$ 

```

4 Resultados e Discussão

Uma instância de Simulação Baseada em Agentes (ABM) complexa com $N = 1.000$ agentes e horizonte temporal $T = 60$ passos (totalizando 60.000 observações) aferiu o *framework* frente às políticas transacionais tradicionais. Os parâmetros de entrada seguiram distribuições log-normais: $\mu \sim \text{Lognormal}(0.5, 0.2)$ (taxa base de interação), $k \sim \text{Lognormal}(-1.0, 0.5)$ (constante de desconto) e $R_{max} \sim \mathcal{N}(100, 15)$.

A validação da tese repousa sobre dois pilares estatísticos fundamentais:

1. **Significância Estatística** ($p < 10^{-300}$): A probabilidade de observarmos a diferença entre os modelos sustentável e *baseline* por mero acaso é virtualmente nula. O teste de Mann-Whitney U corrigido confirma que a melhoria é consequência direta da arquitetura proposta.
2. **Tamanho de Efeito (Cohen’s $d = 3.25$)**: Enquanto o p -valor indica a existência do efeito, o valor de 3.25 quantifica sua magnitude profunda. Em contextos comportamentais, um valor de 0.8 já indica um efeito largo; nosso resultado aponta que a média do grupo sustentável está a mais de três desvios padrão acima da *baseline*, indicando uma transformação radical na experiência atencional.

Traduzimos o conceito abstrato de reserva cognitiva em uma métrica concreta: a Área Sob a Curva (AUC). A AUC sumariza toda a trajetória do agente em um índice de “energia cognitiva” preservada. Constatou-se uma robustez inquestionável do delta AUC exibindo distanciamento estatisticamente colossal. A Tabela 2 detalha os parâmetros utilizados para assegurar a replicabilidade do experimento.

Table 2. Parâmetros de Configuração da Simulação Baseada em Agentes (ABM)

Parâmetro	Descrição	Valor / Distribuição
N	Número de Agentes Simulados	1.000
T	Horizonte Temporal (Passos)	60
μ_{base}	Taxa Base de Interação	$\text{Lognormal}(0.5, 0.2)$
k_{imp}	Constante de Impulsividade	$\text{Lognormal}(-1.0, 0.5)$
R_{max}	Reserva Cognitiva Máxima	$\mathcal{N}(100, 15)$
κ_1	Peso da Velocidade de Scroll	0,15
κ_2	Peso da Alternância de Contexto	0,25
$LIMIAR$	Limiar de Fadiga Crítica	30% de R_{max}

Um sistema *Value-Aligned* deve assegurar que o tempo gasto seja de qualidade. Utilizamos a Divergência de Kullback-Leibler (D_{KL}) para medir a “distância” entre a intenção declarada pelo agente – PRODUTIVIDADE ou ENTRETENIMENTO – e a alocação real de tempo imposta pelo sistema. No modelo proposto, a dispersão é drasticamente reduzida e a mediana aproxima-se de zero, confirmando que em 90% dos casos ($p \in [0.9, 0.1]$) a alocação de conteúdo respeita os objetivos do Sistema 2.

Para afastar a hipótese de uma “solução de laboratório” excessivamente parametrizada, conduzimos testes de estresse via Análise de Sensibilidade Monte Carlo. Realizamos uma varredura massiva no espaço de possibilidades, alterando

parâmetros de fricção (κ_1) e redução de velocidade. A síntese dos resultados aponta que o objetivo central da pesquisa foi atingido: é factível projetar sistemas de recomendação que otimizem a utilidade cognitiva sem prescindir da eficiência técnica. A integração de *Edge AI* com filtros *min-norm* permite que a arquitetura aja como um “airbag”, protegendo o usuário antes do colapso atencional.

Sob a ótica ética, a solução distancia-se de formas de “vigilância benevolente” ao adotar um modelo estritamente *opt-in*. Trata-se de um contrato de autovinculação (*Ulysses Pact*), alinhado a movimentos contemporâneos de bem-estar digital [Center for Humane Technology, 2026], onde a privacidade *by design* é garantida pela execução *on-device*. Rehecemos limitações inerentes à simulação, como a ausência de variáveis sociais exógenas (notificações de terceiros), o que fundamenta a necessidade de futuras validações *in-vivo* e estudos focados em populações vulneráveis [Lyngs et al., 2019; Costello and Linn, 2023; da Saúde, 2021].

5 Conclusão

Este trabalho consolidou e quantificou a viabilidade de uma arquitetura algorítmica voltada à atenção sustentável. Resumimos as quatro frentes de contribuição: (1) Processos de Hawkes para diferenciação qualitativa de consumo; (2) EDO de Reserva para restrição cinemática; (3) *Edge AI* como padrão de privacidade ouro; e (4) Blindagem cognitiva contra o desconto hiperbólico.

Com evidências robustas ($N = 1000, d = 3.25, p < 10^{-300}$), comprovamos que sistemas tecnológicos podem e devem abdicar da predação atencional em favor da agência humana. O *Be-Productive* estabelece um novo paradigma para a Interação Humano-Computador, provando que o alinhamento de valores não é apenas um imperativo filosófico, mas uma factibilidade de engenharia. Fatores atrelados à preservação dos déficits algorítmicos têm de ser resolvidos técnica e programaticamente pela própria base constitutiva. Através dessa comprovação tangível sob formulações abertas pareadas à *Edge AI*, assenta-se um avanço explícito ao nível dos *back-ends* recomendadores.

Apêndice: Disponibilidade de Dados e Código

Todos os módulos em rotinas de ensaios e componentes algorítmicos em *scripts* contendo o rastilho operacional, incluindo registros computados para verificação estatística, encontram-se disponíveis integralmente sob versionamentos padronizados estritos para replicabilidade.

References

Agarwal, A., Usunier, N., Lazaric, A., and Nickel, M. (2024). Disentangling system-1 and system-2 contributions to user return with hawkes processes. *arXiv preprint arXiv:2406.01611*.

- Allcott, H., Gentzkow, M., and Song, L. (2021). Digital addiction: Can it be broken? NBER Working Paper 28936, National Bureau of Economic Research, Cambridge, MA.
- Carvalho, F. (2023). Modelling the recommender alignment problem. Master’s thesis, KU Leuven, Leuven, Belgium.
- Center for AI in Education, Stanford University (2021). A psychiatrist’s perspective on social media algorithms and mental health. Stanford Human-Centered Artificial Intelligence (HAI).
- Center for Humane Technology (2026). Time well spent movement. Center for Humane Technology.
- Citton, Y. (2017). *The Ecology of Attention*. Polity Press, Cambridge.
- Costello, N. and Linn, K. M. (2023). Algorithms, addiction, and adolescent mental health: The case for regulating social media. *American Journal of Law & Medicine*, 49(2–3):134–168.
- da Saúde, B. M. (2021). Saúde mental é saúde: Estratégias e ações do ministério da saúde. Ministério da Saúde, Governo Federal do Brasil.
- Hari, J. (2022). *Foco Roubado: Por Que É Tão Difícil Nos Concentrarmos*. Vestígio, Rio de Janeiro.
- Harris, T. (2019). Optimizing for engagement: How attention extraction became the business model of the internet. Testimony before the U.S. Senate Committee on Commerce, Science, and Transportation. United States Senate.
- Kahneman, D. (2011). *Thinking, Fast and Slow*. Farrar, Straus and Giroux, New York.
- Kushlev, K., Fischer, F., Kirschner, F., Schumann, F., and Könen, T. (2022). A nudge-based intervention to reduce problematic smartphone use: A randomized controlled trial. *Computers in Human Behavior*, 134:107300.
- Lyngs, U., Lukoff, K., Csikszentmihalyi, M., Tinwell, A., Hiniker, A., and Van Kleek, M. (2019). Self-control in cyberspace: Applying dual system theory to a review and analysis of self-control tools for reducing the risk of compulsive smartphone use. In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, New York. ACM.
- Paas, F. and Sweller, J. (2023). Cognitive load theory: Current concepts and novel perspectives. *Educational Psychology Review*, 35:29.
- Stray, J., Vishwanath, A., Beers, H., and O’Brien, B. M. (2021). What are you optimizing for? aligning recommender systems with human values. *arXiv preprint arXiv:2107.10939*. Presented at ICML 2021 Workshop on Human Centered AI.
- Zuboff, S. (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. PublicAffairs, New York.